

Эволюционное программирование и генетические алгоритмы

Отчёт по лабораторной работе № 1

Многомерная оптимизация сложной функции генетическим алгоритмом

Евдокимов Тимофей Андреевич
Группа Б24-527

Вариант: $V = 17$ ($N = 8, Q = 2, Y = 26$)

1 Постановка задачи и индивидуальный вариант

Требуется найти приближённое глобально оптимальное решение задачи

$$\min_{x \in D} f_V(x), \quad x = (x_1, \dots, x_d), \quad (1)$$

где D — ограниченная область поиска, d — размерность варианта.

Индивидуальные параметры:

- $V = 1 + ((17N + 7Q + Y) \bmod 20) = 17$;
- размерность $d = 5 + (V \bmod 6) = 10$;
- область поиска $x_i \in [-1, 1]$ для всех $i = 1, \dots, 10$.

Целевая функция:

$$f(x) = \sum_{i=1}^d |x_i|^{2 + \frac{4(i-1)}{d-1}}. \quad (2)$$

При $d = 10$ показатели степеней для координат $i = 1, \dots, 10$ равны соответственно

2, 2.44, 2.89, 3.33, 3.78, 4.22, 4.67, 5.11, 5.56, 6.

Теоретический глобальный минимум известен аналитически:

$$f(0, 0, \dots, 0) = 0, \quad (3)$$

он достигается в единственной точке $x^* = (0, \dots, 0)$.

Цель работы: освоить базовый генетический алгоритм для непрерывной многомерной оптимизации: вещественное представление, оценивание фитнес-функцией, селекцию, рекомбинацию, мутацию, обработку ограничений и экспериментальный анализ.

2 Формальное описание пространства решений, целевой функции и ограничений

Пространство решений:

$$D = [-1, 1]^{10} \subset \mathbb{R}^{10}. \quad (4)$$

Целевая функция $f : D \rightarrow \mathbb{R}_{\geq 0}$ задана формулой (2). Она непрерывна на D и неотрицательна, причём $f(x) \geq 0$ и $f(x) = 0$ тогда и только тогда, когда $x = 0$.

Ограничения: в постановке нет ограничений-неравенств или равенств, кроме естественного ограничения «точка должна лежать в области D ». Формально задача записывается как

$$\min_{x \in \mathbb{R}^{10}} f(x) \quad \text{при} \quad -1 \leq x_i \leq 1, \quad i = 1, \dots, 10. \quad (5)$$

Обработка границ реализуется как *clamping* — покоординатное обрезание к ближайшей границе отрезка после операторов вариации.

3 Представление особи

Генотип — вектор вещественных чисел длины 10:

$$g = (x_1, x_2, \dots, x_{10}) \in \mathbb{R}^{10}. \quad (6)$$

Фенотип совпадает с генотипом: особь интерпретируется как точка в области D без дополнительного декодирования. Процедура декодирования не требуется, поскольку используется вещественное кодирование, эквивалентное представлению решения задачи.

Фитнес особи — это значение целевой функции $f(g)$. Задача минимизационная, поэтому особь считается «лучше» другой, если её фитнес меньше.

4 Описание эволюционного алгоритма и операторов

Реализован «канонический» поколенческий генетический алгоритм со следующими компонентами.

4.1 Инициализация

Популяция из $P = 100$ особей генерируется покоординатно равномерным распределением на $[-1, 1]^{10}$.

4.2 Оценка фитнес

Все особи оцениваются функцией f . Учёт числа обращений к f ведётся явно, чтобы обеспечить равенство бюджетов при сравнениях.

4.3 Селекция родителей

Турнирная селекция с размером турнира $k = 3$. Для получения P родителей выполняется P турниров: каждый раз случайно выбираются $k = 3$ особей, и победителем становится особь с минимальным значением f . Турнирная селекция устойчива к «супер-особям», не требует масштабирования значений f и легко реализуется.

4.4 Кроссовер

Арифметический кроссовер с вероятностью $p_c = 0.9$. Для пары родителей a, b и случайного $\alpha \sim U(0, 1)$ потомки имеют вид

$$c_1 = \alpha a + (1 - \alpha)b, \quad c_2 = (1 - \alpha)a + \alpha b. \quad (7)$$

С вероятностью $1 - p_c$ пара передаётся потомкам без изменений. Арифметический кроссовер сохраняет корректность точки (выпуклая комбинация точек из D лежит в D), так как D — выпуклое множество.

4.5 Мутация

Гауссовская мутация по генам с вероятностью p_m на каждый ген и масштабом $\sigma = 0.1$. Для каждого гена независимо:

$$x'_i = x_i + \mathbb{1}\{\xi_i < p_m\} \cdot \mathcal{N}(0, \sigma^2) \quad (8)$$

4.6 Обработка границ

После кроссовера и мутации применяется **clamping**:

$$x_i \leftarrow \min(\max(x_i, -1), 1). \quad (9)$$

4.7 Элитизм

Две лучшие особи текущего поколения копируются в следующее поколение без изменений, вытесняя двух худших потомков. Это гарантирует, что лучшее найденное решение не будет потеряно.

4.8 Критерий останова

Бюджет — **50 000 вычислений** фитнес-функции. Это число выбрано единым для всех серий экспериментов, чтобы сравнение алгоритмов было честным.

4.9 Параметры алгоритма

Таблица 1: Параметры реализованного ГА.

Параметр	Значение
Размер популяции P	100
Вероятность кроссовера p_c	0.9
Вероятность мутации на ген p_m	0.1 (A) / 0.3 (B)
Масштаб мутации σ	0.1
Размер турнира k	3
Элитизм	2 особи
Бюджет вычислений f	50 000
Число независимых запусков	20 (на каждую серию)
Seed	1, 2, ..., 20

5 Блок-схема алгоритма




Рис. 1: Блок-схема реализованного генетического алгоритма.

6 Обоснование выбора операторов

Почему турнирная селекция. При минимизации абсолютные значения f могут быть очень разными по величине (от 10^0 до 10^{-13} в разных запусках), поэтому рулеточная селекция требовала бы ручного масштабирования и подбора сигмы. Турнирная селекция такой проблемы не имеет: сравниваются только значения f двух-трёх особей между собой. Размер $k = 3$ даёт умеренное селективное давление, достаточное для интенсификации поиска, но не приводящее к мгновенной потере разнообразия.

Почему арифметический кроссовер. Для вещественных векторов это самый простой корректный оператор: выпуклая комбинация двух допустимых точек лежит в

D , поэтому потомок заведомо не выходит за границы. Он не привязан к осям координат, что важно при анизотропной целевой функции.

Почему гауссовская мутация. Гауссовский шум — стандартный выбор для непрерывных пространств: он не имеет выделенного направления, симметричен, а его масштаб σ легко настраивается. С вероятностью p_m на ген достигается нужный баланс между исследованием (мутации чаще — шире осмотр) и использованием (мутации реже — сохранение найденных решений).

Почему clamping. Обрезание к границе проще отражения или регенерации и не вносит дополнительной случайности: вышедшая за границу координата «прижимается» к ней. Вблизи оптимума (в центре области) она практически не срабатывает.

Почему элитизм. Без него лучшая найденная особь может быть потеряна из-за неудачной мутации или кроссовера. С двумя элитными особями алгоритм монотонно не ухудшает лучшее значение, что удобно для анализа сходимости.

7 Результаты серии запусков

Проведено три серии по 20 независимых запусков каждая при одинаковом бюджете 50 000 вычислений f :

- **A** — базовая конфигурация ГА, $p_m = 0.1$;
- **B** — та же конфигурация, но $p_m = 0.3$ (изменён один фактор);
- **Random** — случайный поиск тем же бюджетом (baseline).

Таблица 2: Описательная статистика по 20 запускам для каждой серии.

Серия	best	mean	median	std	worst
A ($p_m = 0.1$)	$7.867 \cdot 10^{-15}$	$1.152 \cdot 10^{-13}$	$7.732 \cdot 10^{-14}$	$1.122 \cdot 10^{-13}$	$3.737 \cdot 10^{-13}$
B ($p_m = 0.3$)	$6.159 \cdot 10^{-9}$	$5.911 \cdot 10^{-8}$	$4.469 \cdot 10^{-8}$	$5.184 \cdot 10^{-8}$	$1.972 \cdot 10^{-7}$
random search	$1.827 \cdot 10^{-2}$	$4.624 \cdot 10^{-2}$	$4.086 \cdot 10^{-2}$	$2.048 \cdot 10^{-2}$	$8.470 \cdot 10^{-2}$




Рис. 2: Сходимость ГА: среднее best-so-far по 20 запускам и диапазон [min, max].




Рис. 3: Распределение финальных значений f по сериям (по одной панели на серию).

Все серии экспериментов выполнялись при одинаковом бюджете 50 000 вычислений f , поэтому число обращений к фитнес-функции во всех запусках одинаково и не является параметром сравнения. Время работы алгоритма зависит от аппаратного обеспечения и не использовалось как критерий эффективности

8 Анализ результатов

8.1 ГА против случайного поиска

Средний финальный результат серии A равен $1.15 \cdot 10^{-13}$, а серии random — $4.62 \cdot 10^{-2}$. Это означает, что ГА нашёл решения **точнее случайного поиска примерно на 11 порядков** при абсолютно одинаковом числе обращений к фитнес-функции. Даже худший запуск ГА в конфигурации A ($3.74 \cdot 10^{-13}$) на 10 порядков лучше лучшего запуска случайного поиска ($1.83 \cdot 10^{-2}$).

Этот результат полностью ожидаем и служит главным подтверждением эффективности ГА: селекция и кроссовер позволяют постепенно концентрировать популяцию вблизи глобального минимума, тогда как случайный поиск продолжает «размазывать» точки по всему гиперкубу и не имеет механизма интенсификации.

8.2 Влияние вероятности мутации

Конфигурация А ($p_m = 0.1$) устойчиво превосходит В ($p_m = 0.3$) примерно на 5–6 порядков по всем статистикам:

Таблица 3: Сравнение конфигураций А и В.

Метрика	А	В	Отношение
mean	$1.15 \cdot 10^{-13}$	$5.91 \cdot 10^{-8}$	$\sim 5 \cdot 10^5$
median	$7.73 \cdot 10^{-14}$	$4.47 \cdot 10^{-8}$	$\sim 6 \cdot 10^5$
best	$7.87 \cdot 10^{-15}$	$6.16 \cdot 10^{-9}$	$\sim 8 \cdot 10^5$
worst	$3.74 \cdot 10^{-13}$	$1.97 \cdot 10^{-7}$	$\sim 5 \cdot 10^5$

Причина — **избыточное разрушение решений**. При $d = 10$ и $p_m = 0.3$ каждый потомок в среднем мутирует по $d \cdot p_m = 3$ генам. Это значит, что хорошие сочетания координат, найденные кроссовером и селекцией, регулярно «разбиваются» мутацией ещё до того, как элитизм успевает их зафиксировать. ГА в конфигурации В превращается в более «шумный» поиск: он всё ещё значительно лучше случайного (на 6 порядков по среднему), но не успевает за 50 000 вычислений f дойти до области сверхмалых значений f .

Напротив, $p_m = 0.1$ в среднем мутирует один ген на потомка — этого достаточно для исследования, но мало для разрушения полезных комбинаций.

Содержательный вывод: для данной функции и данной размерности оптимальное значение p_m находится ближе к $1/d$, чем к большим значениям. Баланс «исследование vs использование» в нашей задаче смещён в сторону более аккуратной мутации.

8.3 Разброс результатов

- Серия А: разброс (worst/best) ≈ 47 раз;
- Серия В: разброс ≈ 32 раза;
- Random: разброс ≈ 5 раз.

У ГА относительный разброс больше, потому что он «дожимает» решение вблизи нуля, где даже небольшие различия в траектории поиска дают заметные различия в порядке величины f . Разброс же случайного поиска определяется только геометрией равномерного распределения и не зависит от «успеха» поиска.

8.4 Почему функция сложна для локального и случайного поиска

Целевая функция $f(x) = \sum_{i=1}^{10} |x_i|^{p_i}$ с показателями $p_i \in [2, 6]$ обладает несколькими неудобными свойствами для простых методов.

1. **Анизотропия (плохая обусловленность).** Координаты входят с разными степенями: при $i = 1$ показатель равен 2, при $i = 10$ — 6. Это означает, что «крутизна» функции по разным осям различается в разы. Методы, оперирующие всеми координатами одинаково (простой покоординатный спуск, наискорейший градиентный спуск с постоянным шагом), будут медленно сходиться по «пологой» координате и постоянно перескакивать по «крутой».
2. **Плоская область вблизи минимума.** При больших показателях степени функция $|x_i|^6$ вблизи нуля ведёт себя как очень плоская функция: производная стремится к нулю быстрее, чем у квадратичной. Это дополнительно затрудняет сходимость градиентных методов с малым шагом.
3. **Малая мера окрестности минимума.** Рассмотрим шар радиуса r вокруг нуля в $\mathbb{R}^{10}$. Его доля в гиперкубе $[-1, 1]^{10}$ равна r^{10} . Даже для $r = 0.1$ это 10^{-10} : случайно сгенерированная точка почти наверняка окажется далеко от оптимума. Именно поэтому случайный поиск за 50 000 попыток не может подобраться близко к минимуму.
4. **Нулевой градиент в оптимуме, но не квадратичная функция.** Стандартные градиентные методы опираются на локальную квадратичную аппроксимацию. При показателях степени выше 2 эта аппроксимация становится неадекватной всё ближе к минимуму.

Эволюционный алгоритм не использует ни градиента, ни предположения о квадратичности, и потому на этой задаче работает эффективно: он строит распределение поиска по популяции и постепенно сжимает его вокруг глобального минимума независимо от вида f .

9 Содержательные выводы

1. **ГА существенно превосходит случайный поиск** на данной задаче при том же бюджете вычислений: по среднему результату разрыв составляет около 11 порядков. Это оправдывает применение эволюционного подхода для многомерной непрерывной оптимизации.
2. **Вероятность мутации — критичный параметр.** Слишком высокая p_m (0.3 при $d = 10$) ухудшает средний результат на 5–6 порядков из-за разрушения полезных комбинаций генов. Для данной задачи более подходящим оказалось значение $p_m = 0.1$, близкое к $1/d$.
3. **Элитизм + турнирная селекция + арифметический кроссовер** образуют минимальный, но достаточный набор операторов для получения решений порядка 10^{-13} за 50 000 вычислений f . Никакие дополнительные операторы (адаптивный σ , ранговая селекция, SBX и т. п.) для достижения этого уровня не потребовались.
4. **Разброс финальных результатов между запусками** значителен (до 47 раз у конфигурации A), что подтверждает обязательность серии независимых запусков: единичный удачный запуск не является доказательством эффективности метода.

10 Оценка полученного результата

Полученный результат **следует считать хорошим** для поставленной задачи. Обоснование:

1. Глобальный минимум $f^* = 0$ известен, и лучший результат серии А равен $7.87 \cdot 10^{-15}$ — отличие от оптимума составляет менее 10^{-14} в абсолютной шкале. Для практических приложений это фактически оптимум.
2. Медиана серии А равна $7.73 \cdot 10^{-14}$, то есть **больше половины запусков** достигают точности, отличающейся от оптимума в 14-м знаке после запятой. Это не единичная удача, а устойчивое поведение метода.
3. Даже худший запуск конфигурации А ($3.74 \cdot 10^{-13}$) — это решение, которое с инженерной точки зрения неотлично от оптимума: относительная точность $\sim 10^{-13}$.
4. Сравнение с двумя baseline (В и random search) показывает, что выбранная конфигурация операторов и параметров действительно эффективнее альтернатив при том же бюджете вычислений.

Вместе с тем необходимо оговорить границы применимости полученного вывода:

- Функция f **унимодална** и симметрична: единственный минимум находится в нуле. Задача не содержит «обманных» локальных минимумов, что делает её относительно лёгкой для ГА. На многоэкстремальных функциях (Растрингин, Швифель, Михалевич) разрыв между ГА и случайным поиском был бы меньше, а требования к диверсификации популяции — выше.
- Использованный бюджет 50 000 вычислений f при $P = 100$ соответствует 500 поколениям. При меньшем бюджете конфигурация с $p_m = 0.1$ могла бы не успеть «дожать» решение, и сравнение с В могло бы выглядеть иначе.

Тем не менее в рамках поставленной задачи — минимизировать функцию различных степеней при $d = 10$ и бюджете 50 000 — реализованный ГА показал результаты, близкие к теоретическому оптимуму, и подтвердил свою эффективность по сравнению с базовым случайным поиском.